基于深度学习的 IMDB 数据情感分析

(终期报告)

小组成员

司恩泽 2120171050 安骄阳 2120170998

李安民 2120171027 邢博文 2120171082 董永银 2120171007

内容与意义

情感分析(Sentiment analysis)是自然语言处理(NLP)领域的一个任务,又称倾向性分析,意见抽取(Opinion extraction),意见挖掘(Opinion mining),情感挖掘(Sentiment mining),主观分析(Subjectivity analysis)等,它是对带有情感色彩的主观性文本进行分析、处理、归纳和推理的过程,如从电影评论中分析用户对电影的评价(positive、negative),从商品评论文本中分析用户对商品的"价格、大小、重量、易用性"等属性的情感倾向。

电影评论,简称影评,是对一部电影的导演、演员、镜头语言、拍摄技术、剧情、线索、环境、色彩、光线等进行分析和批评,又称电影批评。电影评论的目的在于分析、鉴定和评价蕴含在银幕中的审美价值、

认识价值、社会意义、镜头语言等方面,达到拍摄影片的目的,解释影片中所体现出的道理,既能通过分析影片的成败得失,帮助导演开阔视野,提高创作水平,以促进电影艺术的繁荣和发展;还能通过分析和评价,影响观众对影片的理解和鉴赏,提高观众的欣赏水平,从而间接促进电影艺术的发展。

分析方法

现阶段主要的情感分析方法主要有两类:

基于词典的方法:该方法主要通过制定一系列的情感词典和规则,对文本进行段落拆解、句法分析,计算情感值,最后通过情感值来作为文本的情感倾向依据。

基于机器学习的方法:分为(1)基于传统机器学习的方法;(2)基于深度学习的方法。该方法大多将问题转化为一个分类问题来看待,对于情感极性的判断,将目标情感分类 2 类:正、负,或者根据不同程度分为 1-5 类。对训练文本进行人工标标注,然后进行有监督的机器学习过程。

本文将用三种方法循序渐进地讲述使用深度学习对 IMDB 评论进行情感分析。这三种方法为: MLP、LSTM、BiLSTM+Attention。

目标与功能

本文主要基于深度学习方法对 IMDB 电影评论进行分析, 这其实是一个分类问题, 将 IMDB 电影评论分为正面评价 (positive) 和负面评价 (negative)。

训练出的结果作为评论电影好坏的模型。

过程与结果

1、数据的准备

该电影评论是来自 IMDb 中的电影评论,数据集一共包含了 25000 条关于电影的正面评论和负面评论,数据的组织格式就是下图所示 (review 是评论文本, sentiment 是情感分类标注,1 代表 positive,0 代表 negative):

1 id sentiment review
2 *5914.0° 1 *With all this stuff going down at the moment with NV 1've started listening to his music, watching the odd documentary here and there, watched The Niz 3 *2931.9° 1 *V'The Classic War of the Worldn' by Timothy Bines is a very entertaining film that obviously goes to great effort and lengths to faithfully recreate B 4 *7795.2° 1 *The file starts with a manager (dicholar Bell) giving welloose inversors (Gobert Carastanic Primal Park . A secret project mustaling a primal minal u 5 *1800.2° 0 *The file starts with a manager (dicholar Bell) giving wellows (Gobert Carastanic Primal Park . A secret project mustaling a primal minal u 5 *1800.2° 0 *The mast be assumed that those who preside this film ('the greaters filmed opera ever,'V dich': I read somewhere) either don't care for opera, don't c 1 *1800.2° 0 *The most to know why people which his has a some his primal film for the start with a some start of the start with a secret project benefit of the start of th

2、数据预处理

(1) 在读出数据之后,需要对数据进行一些处理,例如过滤掉一些非 ASCII 字符,清洗掉一些换行符,将大写字母转换为小写等。

```
def clean_str(string):
    Tokenization/string cleaning for dataset
    Every dataset is lower cased except
    string = re.sub(r"\\", "", string)
    string = re.sub(r"\\", "", string)
    string = re.sub(r"\\", ", string)
    return string.strip().lower()

PATH = 'E:/dataset/IMDB_movie_reviews/labeledTrainData.tsv'
data_train = pd.read_csv(PATH, sep='\t')
print(data_train.shape)

texts = []
labels = []

for idx in range(data_train.review.shape[0]):
    text = BeautifulSoup(data_train.review[idx], "lxml")
    texts.append(clean_str(text.get_text())) #.encode('ascii', 'ignore')
    labels.append(data_train.sentiment[idx])
```

(2) 将数据序列化,并统一长度(这里统一句子长度为 1000, 多的截断,少的补 0)。

```
indices = np.arange(data.shape[0])
np.random.shuffle(indices)
data = data[indices]
labels = labels[indices]

nb_validation_samples = int(VALIDATION_SPLIT * data.shape[0])
x_train = data[:-nb_validation_samples]
y_train = labels[:-nb_validation_samples]
x_val = data[-nb_validation_samples:]
y_val = labels[-nb_validation_samples:]
```

(3) 将数据序列化之后,每一句话就变成了固定长度(1000)的 index 序列,每一个 index 对应一个词语。接下来我们将 index 对应到 词语的 word Embedding(词向量),这里使用的是 glove.6B.100d,即每个词用 100 维向量表示。

```
GLOVE_PATH = 'E:/model/nlp/glove.6B.100d.txt'
embeddings_index = {}
f = open(GLOVE_PATH, encoding='utf-8')
for line in f:
    values = line.split()
    word = values[0]
    coefs = np.asarray(values[1:], dtype='float32')
    embeddings_index[word] = coefs
f.close()
print('Total %s word vectors.' % len(embeddings_index))
```

the -0.038194 -0.24487 0.72812 -0.39961 0.083172 0.043953 -0.39141 0.3344 -0.57545 0.087459 0.28787 -0.06731 0.30906 -0.26384 -0.

7, -0.10767 0.11053 0.59912 -0.54361 0.67396 0.10663 0.038867 0.35481 0.06351 -0.094189 0.15786 -0.81665 0.14172 0.21939 0.58505 -0.

8, -0.33979 0.20941 0.466348 -0.64792 -0.38377 0.038034 0.17127 0.15978 0.46619 -0.019169 0.41479 -0.34349 0.26872 0.04464 0.42131 of -0.1529 -0.24279 0.89837 0.16996 0.55516 0.48784 -0.58826 -0.17982 -1.3581 0.42541 0.15377 0.24215 0.13474 0.41193 0.67043 -0. to -0.1897 0.050024 0.19084 -0.049184 -0.089737 0.21006 -0.54952 0.098377 -0.20135 0.34241 -0.092677 0.161 -0.13268 -0.2816 0.187 and -0.071953 0.23127 0.023731 -0.50638 0.33923 0.19599 -0.32943 0.18364 -0.18057 0.28963 0.20448 -0.5496 0.27399 0.58327 0.20468 in 0.085703 -0.22201 0.16569 0.13373 0.38239 0.35401 0.01287 0.22461 -0.43817 0.50164 -0.35874 -0.34983 0.055156 0.69648 -0.17958 a -0.27086 0.044006 -0.02026 -0.17395 0.6444 0.71213 0.3551 0.47138 -0.29637 0.54427 -0.72294 -0.0047612 0.040611 0.043238 0.2972 -0.30457 -0.23645 0.17576 -0.72854 -0.28944 0.22564 0.26587 0.02539 -0.074775 -0.3766 -0.057774 0.12159 0.34384 0.41928 -0.233 's 0.58854 -0.2025 0.73479 -0.68338 -0.19675 -0.1802 -0.39177 0.34172 -0.60561 0.63816 -0.26695 0.36486 -0.40479 -0.1134 -0.55712 'or.014401 0.32554 0.14257 -0.099227 0.72536 0.19821 -0.39147 0.34172 -0.60561 0.63816 -0.26695 0.36486 -0.40479 -0.1134 -0.55712 'or.014401 0.32554 0.14257 -0.049227 0.72536 0.19834 -0.095434 0.19613 0.17785 -0.020244 -0.055409 0.33867 0.79396 -0.047124 'or.014614 0.0322 -0.46244 0.46691 0.21816 -0.074584 0.47332 0.080996 -0.22079 -0.12808 -0.05104 0.25029 0.27841 0.77772 'that -0.093337 0.15043 0.58045 -0.13861 0.00473 -0.075549 0.35874 0.03874 0.098295 -0.055610 0.21399 -0.018043 -0.399364 0.74164 0.30221 0.5176 'or.05464 0.41476 1.0322 -0.40244 0.46691 0.21816 -0.074564 0.47332 0.080996 -0.22079 -0.12808 -0.1416 0.50891 0.11568 0.06617 0.05833 0.13665 0.08672 0.08672 0.08672 0.08683 0.23666 0.39104 0.51657 -0.13861 0.02029

3、 MLP 方法

基于多层感知器 (MLP) 对 IMDB 进行分类是非常简单的一种神经网络应用。

在得到文本向量表示之后,可以直接将向量输入 MLP 网络,经过 多层 MLP 训练之后,讲行 softmax 分类。代码如下:

```
sequence_input = Input(shape=(MAX_SEQUENCE_LENGTH,), dtype='int32')
embedded_sequences = embedding_layer(sequence_input)
dense_1 = Dense(100, activation='tanh')(embedded_sequences)
max_pooling = GlobalMaxPooling1D()(dense_1)
dense_2 = Dense(2, activation='softmax')(max_pooling)

model = Model(sequence_input, dense_2)
model.compile(loss='categorical_crossentropy', optimizer='rmsprop', metrics=['acc'])
model.summary()
model.fit(x_train, y_train, epochs=10, batch_size=50, validation_data=(x_val, y_val))
```

我们可以看到结果如下图所示:

```
Output Shape
                       Param # Connected to
  ______
  _____
               (None, 1000)
  input 1 (InputLayer)
  embedding 1 (Embedding)
                 (None, 1000, 100) 8054700 input 1[0][0]
  dense_1 (Dense)
               (None, 1000, 100) 10100 embedding_1[0][0]
  globalmaxpooling1d 1 (GlobalMaxP (None, 100)
                               dense 1[0][0]
  dense 2 (Dense)
               (None, 2)
                      202
                            globalmaxpooling1d 1[0][0]
  ______
  _____
  Total params: 8,065,002
  Trainable params: 10.302
  Non-trainable params: 8,054,700
Train on 20000 samples, validate on 5000 samples
Epoch 1/10
s: 0.4496 - val acc: 0.8108
Epoch 2/10
s: 0.3752 - val acc: 0.8436
Epoch 3/10
s: 0.3527 - val_acc: 0.8552
s: 0.3393 - val_acc: 0.8628
Epoch 5/10
s: 0.3325 - val acc: 0.8616
s: 0.3256 - val acc: 0.8654
Epoch 7/10
s: 0.3358 - val acc: 0.8628
s: 0.3195 - val_acc: 0.8680
Epoch 9/10
20000/20000 [==============] - 2s - loss: 0.2330 - acc: 0.9110 - val los
s: 0.3260 - val acc: 0.8648
Epoch 10/10
20000/20000 [==============] - 2s - loss: 0.2220 - acc: 0.9161 - val_los
s: 0.3192 - val acc: 0.8650
```

可以看到,在第8次迭代,达到最高的准确率86.80%(看来最简单的3层MLP效果还不错)

4、 LSTM 方法

LSTM 算法全称为 Long short-term memory, 最早由 Sepp

Hochreiter 和 Jürgen Schmidhuber 于 1997 年提出,是一种特定形式的 RNN(Recurrent neural network,循环神经网络),而 RNN 是一系列能够处理序列数据的神经网络的总称。

```
sequence_input = Input(shape=(MAX_SEQUENCE_LENGTH,), dtype='int32')
embedded_sequences = embedding_layer(sequence_input)
l_gru = Bidirectional(LSTM(100, return_sequences=False))(embedded_sequences)
dense_1 = Dense(100, activation='tanh')(l_gru)
dense_2 = Dense(2, activation='softmax')(dense_1)

model = Model(sequence_input, dense_2)

model.compile(loss='categorical_crossentropy', optimizer='rmsprop', metrics=['acc'])
model.summary()
model.fit(x_train, y_train, epochs=10, batch_size=50, validation_data=(x_val, y_val))
```

我们可以看到结果如下图所示:

Layer (type)	Output Shape	Param #	Connected to
	:======== :===========================	======	:==========
input_1 (InputLayer)	(None, 1000)	0	
embedding_1 (Embeddi	ng) (None, 100	0, 100) 80	054700 input_1[0][0]
bidirectional_1 (Bidirection	onal) (None, 1000, 2	00) 16080	00 embedding_1[0][0]
attention_layer_1 (Attenti	on_lay (None, 200)	40200	bidirectional_1[0][0]
dense_1 (Dense)	(None, 100)	20100	attention_layer_1[0][0]
dense_2 (Dense)	(None, 2)	202	dense_1[0][0]
		=======	:==========

Total params: 8,276,002 Trainable params: 221,302 Non-trainable params: 8,054,700

```
Train on 20000 samples, validate on 5000 samples
Epoch 1/10
loss: 0.4628 - val acc: 0.7974
Epoch 2/10
loss: 0.3667 - val acc: 0.8418
loss: 0.3283 - val acc: 0.8566
loss: 0.3147 - val acc: 0.8652
loss: 0.3059 - val acc: 0.8760
Epoch 6/10
loss: 0.2988 - val acc: 0.8756
Epoch 7/10
loss: 0.2947 - val acc: 0.8782
Epoch 8/10
loss: 0.3108 - val acc: 0.8736
loss: 0.3183 - val acc: 0.8748
Epoch 10/10
loss: 0.3362 - val_acc: 0.8726
```

可以看到,在第7次迭代达到87.82%的准确率,比 MLP的效果好。

5、 BiLSTM+Attention 方法

Attention模型最早提出是用在图像识别上的,模仿人类的注意力机制,给图像不同的局部赋予不同的权重。在自然语言中使用最早是在机器翻译领域,这里我们在 BiLSTM 的基础上添加一个 Attention Model,即对 BiLSTM 的隐层每一个时间步的向量学习一个权重,也就是在得到句子的向量表示时对评论文本中不同的词赋予不同的权值,然后由这些不同权值的词向量加权得到句子的向量表示。

BiLSTM+Attention 代码如下:

```
sequence_input = Input(shape=(MAX_SEQUENCE_LENGTH,), dtype='int32')
embedded_sequences = embedding_layer(sequence_input)
l_gru = Bidirectional(LSTM(100, return_sequences=True))(embedded_sequences)
l_att = Attention_layer()(l_gru)
dense_1 = Dense(100, activation='tanh')(l_att)
dense_2 = Dense(2, activation='softmax')(dense_1)

model = Model(sequence_input, dense_2)
model.compile(loss='categorical_crossentropy', optimizer='rmsprop', metrics=['acc'])
model.summary()
model.fit(x_train, y_train, epochs=10, batch_size=50, validation_data=(x_val, y_val))
```

我们可以看到结果如下图所示:

Layer (type)	Output Shape	Param #	Connected to
==========	========		==========
input_1 (InputLayer)	(None, 1000)	0	
embedding_1 (Embeddi	ng) (None, 10	00, 100) 8	8054700 input_1[0][0]
bidirectional_1 (Bidirection	onal) (None, 1000, 2	200) 1608	00 embedding_1[0][0]
attention_1 (Attention)	(None, 200)	40400	bidirectional_1[0][0]
dense_1 (Dense)	(None, 2)	402	attention_1[0][0]
	========	=====	

Total params: 8,256,302 Trainable params: 8,256,302

Non-trainable params: 0

```
Train on 20000 samples, validate on 5000 samples
Epoch 1/10
loss: 0.3183 - val acc: 0.8714
Epoch 2/10
loss: 0.2717 - val_acc: 0.8928
Epoch 3/10
loss: 0.2462 - val acc: 0.8984
Epoch 4/10
loss: 0.2430 - val acc: 0.9054
loss: 0.2568 - val_acc: 0.9018
Epoch 6/10
loss: 0.2876 - val acc: 0.9030
Epoch 7/10
loss: 0.3566 - val acc: 0.8990
Epoch 8/10
loss: 0.3851 - val acc: 0.8960
loss: 0.4063 - val acc: 0.8972
Epoch 10/10
loss: 0.5198 - val_acc: 0.8834
```

可以看到, 在第 4 次迭代达到 90.54%的准确率, 证明加 Attention 层确实有效。

分析方法

随着信息时代的快速发展,数据的增量迅速扩大,从数据中挖掘有价值的内容成为了一个重要的研究问题。对于电影影评,充分挖掘用户对于电影的直接情感,,既能通过分析影片的成败得失,帮助导演开阔视野,提高创作水平,以促进电影艺术的繁荣和发展;还能通过分析和评价,影响观众对影片的理解和鉴赏,提高观众的欣赏水平,从而间接促进电影艺术的发展。

本文通过三种方法对电影评论进行了数据挖掘,结果显示不同的方法达到的准确率不同且使用的迭代数不同,综合使用一些方法能达到更好的效果。因此,在数据挖掘中,选用好的模型和方法技巧至关重要。